

---

# Institut National des Langues et Civilisations Orientales

Département Textes, Informatique, Multilinguisme

---

## Titre du mémoire

---

# MASTER

## TRAITEMENT AUTOMATIQUE DES LANGUES

*Parcours :*

*Ingénierie Multilingue*

par

**Martin DIGARD**

*Directeur de mémoire :*

*Damien NOUVEL*

*Encadrant :*

*Florent JACQUEMARD*

Année universitaire 2020/2021



# TABLE DES MATIÈRES

<b>Liste des figures</b>	<b>5</b>
<b>Liste des tableaux</b>	<b>5</b>
<b>Introduction</b>	<b>7</b>
<b>I Contexte général</b>	<b>11</b>
<b>1 État de l'art</b>	<b>13</b>
1.1 Introduction . . . . .	13
1.2 Contenu . . . . .	13
1.3 Conclusion . . . . .	13
<b>2 Méthodes</b>	<b>15</b>
2.1 Introduction . . . . .	15
2.2 Contenu . . . . .	19
2.3 Conclusion . . . . .	19
<b>II Expérimentations</b>	<b>21</b>
<b>3 Corpus</b>	<b>23</b>
3.1 Introduction . . . . .	23
3.2 Comparaisons de transcriptions . . . . .	26
3.3 Contenu . . . . .	30
3.4 Conclusion . . . . .	30
<b>4 Résultats</b>	<b>31</b>
4.1 Introduction . . . . .	31
4.2 Contenu . . . . .	31
4.3 Conclusion . . . . .	31
<b>5 Discussion</b>	<b>33</b>
5.1 Introduction . . . . .	33
5.2 Contenu . . . . .	33
5.3 Conclusion . . . . .	33
<b>Conclusion générale</b>	<b>35</b>
<b>Bibliographie</b>	<b>37</b>
<b>A Documentation</b>	<b>39</b>

A.1	Compilation . . . . .	39
A.2	Les images . . . . .	39
A.3	Les tableaux . . . . .	40
A.4	Mise en forme . . . . .	40
A.5	Formules mathématiques . . . . .	41
A.6	Gestion de la bibliographie . . . . .	41
<b>B</b>	<b>Principes à suivre</b>	<b>43</b>
B.1	Le sujet de votre mémoire . . . . .	43
B.2	L'encadrement du mémoire . . . . .	44
B.3	L'évaluation du mémoire . . . . .	44
B.4	La démarche à suivre pour soutenir . . . . .	45

## **LISTE DES FIGURES**

A.1	Schéma d'annotation défini pour les entités nommées biomédicales . . . . .	39
-----	--	----

## **LISTE DES TABLEAUX**

A.1	Résultats généraux pour chaque expérience . . . . .	40
A.2	Fusion de lignes et de colonnes dans un tableau . . . . .	40



# INTRODUCTION

## Plan de lecture

Un mémoire de recherche ou un article scientifique se composent généralement<sup>1</sup> des chapitres suivants :

- Introduction : présentation générale du contexte et de la problématique traitée, plan suivi dans le mémoire ;
- État de l’art (chapitre 1) : les articles qui traitent du même sujet que vous, présentés en un tout cohérent (*extraire de chaque article lu les points essentiels et présenter dans ce chapitre le résultat de ces lectures en regroupant les articles par point essentiel*) ;
- Corpus (chapitre 3) : le corpus utilisé (*caractéristiques, pré-traitements appliqués*) ;
- Méthodes (chapitre 2) : les méthodes appliquées, avec le détail des expériences réalisées (différentes configurations) ;
- Résultats (chapitre 4) : les résultats obtenus sur chacune des expériences ;
- Discussion (chapitre 5) : la discussion des résultats obtenus (quelle expérience a produit les meilleurs résultats, de manière globale, dans le détail des catégories) avec, si possible, une analyse des erreurs pour comprendre les possibilités d’amélioration ;
- Conclusion : la conclusion globale du mémoire.

En règle générale, l’introduction et la conclusion sont les deux sections de contenu à ne pas être numérotées. Idéalement, chaque chapitre commence par une introduction rapide et se termine par une conclusion rapide pour aider le lecteur à mémoriser et comprendre ce qui a été fait.

---

1. Il est accepté que vous, ou votre directeur de mémoire, estimiez qu’une autre organisation s’impose pour votre problématique de recherche.

## Présentation générale

### Sujet du stage

L'objectif de la transcription automatique de la musique (AMT) [1] est de convertir la performance d'un musicien en notation musicale - un peu comme la conversion de la parole en texte dans le traitement du langage naturel. Elle est considérée comme l'un des problèmes de recherche les plus anciens et les plus difficiles dans le domaine de la recherche d'information musicale (MIR).

Le cas de la transcription de la batterie (DT) est très particulier puisqu'il s'agit d'instruments sans hauteur, d'événements avec (presque) aucune durée et de notations spécifiques. Il a été la source de nombreuses études MIR, voir [2] pour un aperçu. La plupart de ces travaux se concentrent sur des méthodes de calcul pour la détection d'événements sonores de batterie à partir de signaux acoustiques, et sur l'extraction de caractéristiques de bas niveau telles que la classe d'instrument et le moment de l'apparition du son (peak picking). Cependant, très peu d'entre eux ont abordé la tâche de générer une notation musicale (rythmique) lisible à partir des caractéristiques ci-dessus, une étape cruciale dans un contexte musical et loin d'être triviale.

La présente proposition s'intéresse à ce dernier problème, et plus précisément à :

1. l'étude de modèles de langage (LM) incorporant certaines informations musicales de haut niveau nécessaires à la génération de partitions de qualité. On devrait en particulier considérer des hiérarchies d'événements de batterie induisant des placements temporels cohérents et se prêtant à des notations rythmiques faciles à lire pour un batteur entraîné; voir [3] pour des modèles structurés en arbre basés sur la théorie formelle du langage, que nous développons dans le contexte d'outils AMT plus généraux.

2. l'intégration de ces LM avec l'état de l'art des modèles acoustiques (AM) et des méthodes pour les tâches de traitement du signal ci-dessus. Cela nécessite la prise en compte du contexte musical et des informations musicales de haut niveau des LM en plus des caractéristiques acoustiques de bas niveau ci-dessus.

En outre, certaines expériences seront menées sur la base d'ensembles de données publiques, afin d'évaluer l'approche intégrée. Elles devraient couvrir certains cas de motifs rythmiques complexes se chevauchant.

Au-delà de l'intégration de modèles, il sera également intéressant d'étudier comment l'utilisation de LM peut améliorer les résultats de l'AM, voir [2], et ouvrir la voie à la génération entièrement automatisée de partitions de batterie et au problème général de l'AMT de bout en bout. [1]

### Problématique traitée

En entrée : midi (séquence d'événements datés (piano roll) accompagné d'une grammaire pondérée)

⇒ parsing

⇒ global parsing tree

⇒ RI (Représentation Intermédiaire) arbres locaux par instruments

⇒ Sortie (xml, mei, lilypond, . . . )



Minimiser la distance entre le midi et la représentation en arbre.

Le but du stage est d'améliorer qparse, un outil de transcription et d'écriture automatique de la batterie (entre autre)

Le sujet de ce mémoire est de proposer une tâche de reconnaissance du regroupement des notes par les ligatures dans l'écriture de la batterie.

Pour cela, nous utiliserons la logique des systèmes (selon la définition agostinienne).

⇒ Motif répétitif de plusieurs instruments coordonnés accompagnés d'un texte varié joué par un autre instrument de la batterie.

Nous partirons de propositions génériques de systèmes (environs trois systèmes dans différents style de batterie) que nous tenterons de détecter dans le jeu de données groove.

Nous travaillerons aussi sur la détection de répétitions sur plusieurs mesures afin de pouvoir corriger des erreurs sur une des mesures qui aurait dû être identique au autres mais qui présente des différences.

### **Plan suivi dans le mémoire**

- écouter le dataset groove
- observer la structure midi
- décrire la notation de la batterie et transcrire manuellement pour comparer l'input et l'output idéal d'un point de vu théorique.
- Détecter les systèmes dans le dataset.
- Faire des règles de réécriture (rewriting/simplification) et de séparation des voix (reconnaissance de systèmes)



**Première partie**

**Contexte général**



# ÉTAT DE L'ART

## Sommaire

1.1	Introduction . . . . .	13
1.2	Contenu . . . . .	13
1.3	Conclusion . . . . .	13

## 1.1 Introduction

Dans ce chapitre, nous présentons...

## 1.2 Contenu

Une section dans ce chapitre avec un appel cliquable de référence bibliographique [?].

## 1.3 Conclusion

Conclusion de ce chapitre.



## MÉTHODES

## Sommaire

2.1	Introduction . . . . .	15
2.2	Contenu . . . . .	19
2.3	Conclusion . . . . .	19

## 2.1 Introduction

Dans ce chapitre...

## Les systèmes en batterie

Proposition pour la détection de la direction des hampes et pour les ligatures (regroupement des notes et séparation des voix.)

— **Les systèmes :**

⇒ Un système est la combinaison d'un ou plusieurs éléments qui jouent un rythme en boucle (système) et d'un autre élément qui joue un *texte* rythmique variable mais respectant les règles propre au système (texte).

En cas de système, les ligatures forment deux voies :

- Le texte;
- Le système.

*Mettre des exemples de différents systèmes.*

— **Les moulines :**

Lorsqu'il y a plus d'une voie, ils sont prioritaires pour les ligatures.

*Mettre des exemples.*

## Gestion des silences et des têtes de notes

Rythme tree (RT)

- Le symbole "-" est une continuation (liaison) mais pour une partition de batterie, ça serait un silence par défaut sauf peut-être pour les ouvertures de charley et éventuellement les cymbales ou un tom basse qui résonne.

⇒ Question de la (notation noir + silence) vs blanche.

⇒ On privilégierait (noir + silence) puisque les symboles « x » des cymbales ne peuvent pas porter d'indication de durée dans la tête de notes.

Les 3 parties d'une note :

- durée
- hampe
- tête de note (peut aussi indiquer la durée mais en batterie on évitera les blanches, etc.)

source : [https://fr.wikipedia.org/wiki/Note\\_de\\_musique](https://fr.wikipedia.org/wiki/Note_de_musique)

## Définition des têtes de notes et des hauteurs

### Proposition de définition d'un standard de départ

Pour la transcriptions, nous proposons de choisir la base Agostini. La caisse claire centrale sur la portée est aussi centrale sur la batterie est elle est un élément qui conditionne la position des jambes (écart entre les pédales, etc.) ainsi que l'organisation des éléments en hauteur (toms, cymbales, etc.). On pensera en terme de symétrie la répartition des éléments par rapport au point central que constitue la caisse claire. Cette symétrie s'opère en trois dimensions :

- Les hauteurs en terme de fréquences ;
- La hauteur physique des éléments :  
Du bas vers le haut : pédales, toms et caisse, cymbales
- L'ergonomie, qui hiérarchise l'importance des éléments sur la portée (caisse claire au centre, hh-pied et ride sont aux deux extrémités).

## Écriture de partitions

Les partitions pour la transcription manuelle seront écrites avec LilyPond.

Voici un exemple de code :

```
\version "2.22.1"
\language français
{
do' re' mi' fa' sol' la' si' do'' re'' mi'' fa'' sol'' la'' si'' do'''
}
\relative {
do' re mi fa sol la si do re mi fa sol la si do
}
\relative {
do'4. do4. do4
mi2 re
do16 do do do do do8 do16 do do do do do do8 do16
mi8 mi mi mi re re re re
}
```

Avec la commande :

```
$ lilypond fichier.ly
```



On obtient le pdf suivant :



### Bases :

<http://lilypond.org/doc/v2.22/Documentation/learning/simple-notation>

### Percussions et batterie :

<http://lilypond.org/doc/v2.22/Documentation/notation/common-notation-for-percussion>

La définition des symboles a été faite avec lilypond avec le script suivant :

```
$ cat description_notation_0.ly

\version "2.22.1"
\language français

{
% Toutes les hauteurs sont en ut
\clef percussion

% Ne pas appeler la fonction qui dessine les symboles
\override Staff.TimeSignature.stencil = ##f

% Changer la tête de note
\override NoteHead.style = #'cross

% Hauteur de la note + commentaire
do' - "ride"
}

{
\clef percussion
\override Staff.TimeSignature.stencil = ##f
\override NoteHead.style = #'cross
la' - "charley main"
}

{
\clef percussion
```

```

\override Staff.TimeSignature.stencil = ##f
fa'-"tom alto"
}

{
\clef percussion
\override Staff.TimeSignature.stencil = ##f
do'-"caisse claire"
}

{
\clef percussion
\override Staff.TimeSignature.stencil = ##f
sol-"tom basse"
}

{
\clef percussion
\override Staff.TimeSignature.stencil = ##f
mi-"grosse caisse"
}

{
\clef percussion
\override Staff.TimeSignature.stencil = ##f
\override NoteHead.style = #'cross
do-"charley pied"
}

```

## Installation de cmake-3.20.4

Installation de CMake et d'un environnement C++ pour Vim.

```

martin@robot:tests_cpp$ tree -L 3
.
├── bonjour.cpp
├── build
│   ├── Bonjour
│   ├── CMakeCache.txt
│   ├── CMakeFiles
│   │   ├── 3.20.4
│   │   ├── Bonjour.dir
│   │   ├── cmake.check_cache
│   │   ├── CMakeDirectoryInformation.cmake
│   │   ├── CMakeOutput.log
│   │   ├── CMakeTmp
│   │   ├── Makefile2
│   │   ├── Makefile.cmake
│   │   ├── progress.marks
│   │   └── TargetDirectories.txt
│   ├── cmake_install.cmake
│   ├── compile_commands.json
│   └── Makefile
├── CMakeLists.txt
├── compile_commands.json
└── hist_final_1

5 directories, 16 files
martin@robot:tests_cpp$ cat hist_final_1
mkdir build
cd build/
cat ../CMakeLists.txt
cmake -DCMAKE_EXPORT_COMPILE_COMMANDS=ON ..
cp compile_commands.json ..
cmake --build .
./Bonjour
martin@robot:tests_cpp$

```

- Lire sur la réécriture : 1\_articles/1\_rt\_representation
- Lire Qparse : <https://qparse.gitlabpages.inria.fr/>

qparse (version beta) entrée MIDI (groove), sortie MIDI (modifiée) ou partition MEI.

## 2.2 Contenu

Une section dans ce chapitre... Basé sur [2] et sur [3]

### Propositions de règles de ré-écriture

Pour la plupart des instruments mélodiques, la liaison et le point sont les deux seules possibilités en cas d'équivalence rythmique. Mais la batterie offre un 3ème choix pour combler la distance rythmique entre deux notes : les silences.

Les cymbales-crash et les ouvertures de charley constituent le seul cas qui exclut cette option. Le charley car ses ouvertures/fermetures sont presque toujours quantifiées. Les fermetures du charley sont notées soit par un silence (correspondant à une fermeture de la pédale), soit par un écrasement de l'ouverture par un autre coup de charley fermé, au pied ou à la main.

- Tie to dot devient Tie to note&rest  
par exemple : une noire liée à une autre noire devient une noire + un soupir.  
On remplace donc la dernière note d'une liaison par sa valeur en silence. Ceci ne concerne pas les ouvertures de charley, qui sont, avec les cymbales-crash, les seuls indications sonores dont nous considérerons la durée.
- Dans tous les cas, sauf ouverture de hh-pd, Une note sur un temps suivie d'une note en l'air sur le second temps seront écrites : noire sur le temps 1 puis silence + note pertinente sur le temps 2.
- Pour un charley ouvert qui déborde sur le temps d'après, le choix le plus pertinent est-il la note pointée ou la liaison? Je pense que c'est la liaison car il marchera même dans les cas où le point ne marche pas (ex : mauvaise durée)
- une blanche sera écrite noir + soupir.

Voir exemples dans : Stage\_M2\_Inria/2\_Transcriptions\_LilyPond/exemples\_rewriting

Les deux instruments qui seront difficiles à placer seront la caisse claire et le charley au pied car ils ne seront pas toujours affiliés aux mêmes instruments.

## 2.3 Conclusion

Conclusion de ce chapitre.



**Deuxième partie**

**Expérimentations**



## CORPUS

## Sommaire

---

3.1	Introduction . . . . .	23
3.2	Comparaisons de transcriptions . . . . .	26
3.3	Contenu . . . . .	30
3.4	Conclusion . . . . .	30

---

## 3.1 Introduction

Dans ce chapitre... **groove MIDI dataset**

<https://magenta.tensorflow.org/datasets/groove>



Des batteurs pro ont été engagés pour jouer sur un roland td-11

The Groove MIDI Dataset (GMD), has several attributes that distinguish it from existing ones:

- The dataset contains about 13.6 hours, 1,150 MIDI files, and over 22,000 measures of drumming.
- Each performance was played along with a metronome set at a specific tempo by the drummer.
- The data includes performances by a total of 10 drummers, with more than 80% of duration coming from hired professionals. The professionals were able to improvise in a wide range of styles, resulting in a diverse dataset.
- The drummers were instructed to play a mix of long sequences (several minutes of continuous playing) and short beats and fills.
- Each performance is annotated with a genre (provided by the drummer), tempo, and anonymized drummer ID.
- Most of the performances are in 4/4 time, with a few examples from other time signatures.
- Four drummers were asked to record the same set of 10 beats in their own style. These are included in the test set split, labeled `eval-session/groove1-10`.
- In addition to the MIDI recordings that are the primary source of data for the experiments in this work, we captured the synthesized audio outputs of the drum set and aligned them to within 2ms of the corresponding MIDI files.



## Les métadatas :

The metadata file ( `info.csv` ) has the following fields for every MIDI/WAV pair:

Field	Description
drummer	An anonymous string ID for the drummer of the performance.
session	A string ID for the recording session (unique per drummer).
id	A unique string ID for the performance.
style	A string style for the performance formatted as "<primary>/<secondary>". The primary style comes from the Genre List below.
bpm	An integer tempo in beats per minute for the performance.
beat_type	Either "beat" or "fill"
time_signature	The time signature for the performance formatted as "<numerator>-<denominator>".
midi_filename	Relative path to the MIDI file.
audio_filename	Relative path to the WAV file (if present).
duration	The float duration in seconds (of the MIDI).
split	The predefined split the performance is a part of. One of "train", "validation", or "test".

Genre List: afrobeat, afrocuban, blues, country, dance, funk, gospel, highlife, hiphop, jazz, latin, middleeastern, neworleans, pop, punk, reggae, rock, soul

A train/validation/test split configuration is provided for easier comparison of model accuracy on various tasks.

Split	Beats	Fills	Measures (approx.)	Hits	Duration (minutes)
Train	378	519	17752	357618	648.5
Validation	48	76	2269	44044	82.2
Test	77	52	2193	43832	84.3
<b>Total</b>	<b>503</b>	<b>647</b>	<b>22214</b>	<b>445494</b>	<b>815.0</b>

Détails (entre autres tensorflow avec le dataset) à : <https://magenta.tensorflow.org/datasets/groove#license>

Les transcriptions manuelles sont faites à partir des fichiers wav et celles de MuseScore à partir des fichiers MIDI.


## 3.2 Comparaisons de transcriptions

### 0. Prise en main

Pour la prise en main, les transcriptions manuelles ont été faites avec musescore au lieu de lilypond. **Premiers tests sur drummer\_01/session3**

#### *Exemple 1 : 10\_rock-folk\_90\_beat\_4-4*

manuelle



musescore



- Erreur d'indication de mesure ;
- Mauvaise transcription d'une noire.

La noire du 4ème temps se retrouve sur le premier temps de la mesure suivante et elle se transforme en un triolet de double croches dont seules les deux premières seraient jouées.

#### *Exemple 2 : 10\_rock-folk\_90\_beat\_4-4*

manuelle




musescore




- Erreur de quantification : les doubles croches ont été interprétées en quintolet ;

### **Exemple 3 : 2\_jazz-swing\_185\_beat\_4-4**

#### **manuelle**



#### **musescore**




- L'indication de mesure est correcte mais tout a été décalé d'un temps car la première noire sur la caisse claire est jouée sur le 4ème temps et non sur le premier temps de la deuxième mesure comme l'indique la transcription de musescore.
- Les toms basses des 1er et 2ème temps de la mesure musescore auraient dû être sur les temps et non décalés d'une double croche vers la droite.

### **Solutions aux pb rencontrés**

Existe-t-il un moyen de rectifier les erreurs d'indication de mesure et de décalage de temps des partitions MuseScores.

- Changer dans manuellement dans MuseScore l'indication de mesure<sup>1</sup> fonctionne avec la transcription du MIDI.

1. <https://musescore.org/fr/manuel/indications-de-mesure>



- Pour décaler tout d'un temps, on peut sélectionner les mesures en question en cliquant sur la première note de la séquence et en maj-cliquant sur la dernière, puis Ctrl-X Ctrl-V pour replacer le tout au bon endroit.<sup>2</sup>

À partir de la prochaine section, les indications de mesures erronées ou les décalages de temps qui ont des répercussions sur l'ensemble de la partition seront corrigés avant l'analyse.

### Seconds tests sur drummer\_01/session1

#### Exemple 1 : 1\_funk\_80\_beat\_4-4 manuelle



**musescore**



- On dirait que lorsque certaines notes sont proches, elles se resserrent et suppriment celles qui aurait dû être sur le temps.

#### Exemple 2 : 1\_funk\_80\_beat\_4-4 1\_funk\_80\_beat\_4-4

**manuelle**



**musescore**

2. <https://musescore.org/fr/node/276292>



- La caisse claire de la 2ème croche du 4ème temps de la 1ère mesure se transforme en une combinaison de quadruple/quintuple/double croches liées qui commence par un soupir et finit en débordant sur le premier temps de la mesure suivante.


## 1. Transcription des flas

À partir de maintenant, les transcriptions manuelles seront faites avec LilyPond.

### Sur la question des flas

Des exemples de notation flas tom/caisse-claire existent dans des partitions récentes (rythmique binaire J.-F. Juskowiak).

⇒ Ils faudra donc les prendre en compte dans les comparaisons de transcriptions.  
De gauche à droite : transcription musescore, transcription manuelle.



Il manque des charley, je dois trouver comment faire des accords avec des têtes de notes différentes.

## 2. Autres

- Chercher des exemples de silences, triplets.
- Faire les observations avec des notations plus ou moins chargées.

## 3.3 Contenu

Une section dans ce chapitre...

## 3.4 Conclusion

Conclusion de ce chapitre.

## RÉSULTATS

### Sommaire

4.1	Introduction . . . . .	31
4.2	Contenu . . . . .	31
4.3	Conclusion . . . . .	31

### 4.1 Introduction

Dans ce chapitre...

### 4.2 Contenu

Une section dans ce chapitre...

### 4.3 Conclusion

Conclusion de ce chapitre.





## DISCUSSION

### Sommaire

5.1	Introduction . . . . .	33
5.2	Contenu . . . . .	33
5.3	Conclusion . . . . .	33

### 5.1 Introduction

Dans ce chapitre...

### 5.2 Contenu

Une section dans ce chapitre...

### 5.3 Conclusion

Conclusion de ce chapitre.



# CONCLUSION GÉNÉRALE

Dans ce mémoire, nous avons traité de la problématique...



## BIBLIOGRAPHIE

- [1] Chih-Wei Wu, Christian Dittmar, Carl Southall, Richard Vogl, Gerhard Widmer, Jason Hockman, Meinard Müller, and Alexander Lerch. A review of automatic drum transcription. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 26(9) :1457–1483, 2018. – Cité page 8.
- [2] Florent Jacquemard, Pierre Donat-Bouillud, and Jean Bresson. A Term Rewriting Based Structural Theory of Rhythm Notation. Research report, ANR-13-JS02-0004-01 - EFFICACe, March 2015. – Cité page 19.
- [3] Florent Jacquemard, Adrien Ycart, and Masahiko Sakai. Generating equivalent rhythmic notations based on rhythm tree languages. In *Third International Conference on Technologies for Music Notation and Representation (TENOR)*, Corroña, Spain, May 2017. Helena Lopez Palma and Mike Solomon. – Cité page 19.





## DOCUMENTATION

### A.1 Compilation

La compilation d'un fichier  $\text{\LaTeX}$  nommé « modele.tex » se fait au moyen des étapes suivantes (en lignes de commande) :

- `pdflatex modele` (première compilation pour l'appel des différentes fonctionnalités contenues dans le mémoire);
- `bibtex modele` (préparation de la bibliographie);
- `makeindex modele` (préparation de l'index);
- `pdflatex modele` (à faire 2 fois, produit le PDF complet).

### A.2 Les images

Le schéma A.1 présente le schéma d'annotation en entités nommées du domaine biomédical que nous avons utilisé pour annoter nos corpus de données.

FIGURE A.1 – Schéma d'annotation défini pour les entités nommées biomédicales

L'intégration d'une image (format PDF, PNG) se fait au moyen de la commande `\includegraphics{fichier.pdf}` avec d'éventuelles options entre crochets pour spécifier la taille de l'image (height, width) par rapport à la page.

### A.3 Les tableaux

Pour réaliser un tableau en  $\text{\LaTeX}$ , la syntaxe ressemble à (voir tableau A.1) :

Expérience	Rappel	Précision	F-mesure
Baseline	0,372	0,500	0,427
Lexique	0,907	0,903	0,905
Apprentissage	0,880	0,942	0,910

TABLE A.1 – Résultats généraux pour chaque expérience

Dans la commande `\begin{tabular}{|l|c|c|r|}` on définit le nombre de colonnes (ici 4), la manière dont le texte est mis en forme dans chaque colonne (`l=left`, `c=center`, `r=right`), et le séparateur de colonne (ici une ligne verticale). La commande `\hline` permet de tracer une ligne horizontale. La commande `\caption{Titre ou légende}` permet de définir la légende d'un tableau. Et la commande `\label{nom}` permet de nommer le tableau pour le désigner dans le corps du texte avec la commande `\ref{nom}` (e.g., tableau A.1).

Les commandes `\multirow{n}{*}{Texte}` et `\multicolumn{n}{c}{Texte}` permettent de fusionner plusieurs lignes et plusieurs colonnes, avec  $n$  le nombre de lignes ou colonnes fusionnées. La commande `\cline{2-4}` permet de dessiner une ligne horizontale de la colonne 2 à la colonne 4 (voir tableau A.2).

Expérience	Mesures		
	Rappel	Précision	F-mesure
Baseline	0,372	0,500	0,427
Lexique	0,907	0,903	0,905
Apprentissage	0,880	0,942	<b>0,910</b>

TABLE A.2 – Fusion de lignes et de colonnes dans un tableau

### A.4 Mise en forme

Il est possible de mettre du texte en *emphase* `\emph{texte}`, en *version penchée* `\textsl{texte}`, en **gras** `\textbf{texte}`, en version Sans Serif (similaire à Arial et Helvetica) `\textsf{texte}` ou encore en PETITES CAPITALES `\textsc{Texte}`. Il n'est pas recommandé d'utiliser le souligné au vu de l'effet produit. Pour ajouter une note de bas de page<sup>1</sup>, on utilise la commande `\footnote{Contenu}`. L'espace insécable (c.-à-d. qui ne peut pas être coupée si elle est en fin de ligne), est représentée par le tilde. On l'utilise généralement avant un appel de référence, ou avant la référence d'un tableau ou d'une figure `Tableau~\ref{clé}`.

Il est possible de ne pas numéroté les titres de section, sous-section, etc., en utilisant la commande `\section{Titre}`. Dans ce cas, il est nécessaire d'ajuster les mini tables des matières qui figurent au début de chaque chapitre au moyen de la commande `\adjustmtc` en intégrant cette commande autant de fois que nécessaire avant la commande `\minitoc`.

1. Les notes de bas de page sont numérotées automatiquement en fonction de leur utilisation tout au long du texte. Avec ce modèle, la numérotation est remise à 1 à chaque début de chapitre.



Pour forcer un saut de page, on utilise la commande `\newpage` et pour un saut de ligne `\\`

## A.5 Formules mathématiques

Le rappel (formule A.1) mesure le nombre d'éléments correctement étiquetés par le système (vrais positifs) rapporté au nombre d'éléments étiquetés dans la référence (vrais positifs et faux négatifs).

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}} \quad (\text{A.1})$$

La précision (formule A.2) mesure le nombre d'éléments correctement étiquetés par le système (vrais positifs) rapporté au nombre total d'éléments étiquetés par le système (vrais et faux positifs).

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}} \quad (\text{A.2})$$

La F-mesure (formule A.3) est la moyenne harmonique pondérée du rappel et de la précision. La valeur accordée à  $\beta$  permet de pondérer le rappel ou la précision, ou d'équilibrer les deux mesures (avec  $\beta = 1$ ).

$$\text{F-mesure} = \frac{(1 + \beta^2) \times \text{précision} \times \text{rappel}}{\beta^2 \times \text{précision} + \text{rappel}} \quad (\text{A.3})$$

Les plus motivés d'entre vous pourront également réaliser des figures (arbre syntaxique, histogramme, diagramme circulaire, etc.) directement sous  $\text{\LaTeX}$  en utilisant le package Tikz<sup>2</sup> une fois qu'ils auront terminé la rédaction de leur mémoire pour ne pas perdre de temps dès le départ...

## A.6 Gestion de la bibliographie

La bibliographie figure dans un fichier nommé « biblio.bib ». Ce fichier peut être édité dans un éditeur de texte classique (*emacs*, *vi*, *notepad*), ou par le biais d'un outil de gestion de bibliographie tel que JabRef, un programme Java qui permet de gérer efficacement les fichiers \*.bib et de remplir les différents champs nécessaires à chaque entrée.

### A.6.1 Appels de référence

On appelle les références au moyen de la commande `\cite{clé}` avec une clé de citation qui est définie dans la bibliographie. On intègre généralement une référence bibliographique après avoir introduit le concept. Par exemple : nos expériences en approche statistique reposent sur le formalisme des CRF [?] implémenté dans l'outil WAPITI [?]. Nous avons suivi le protocole défini par [?, p. 3] pour constituer les annotations de corpus.

Il est possible de citer plusieurs articles en même temps en séparant chaque clé par une virgule. Par exemple : notre travail repose sur la détection d'entités nommées [?, ?] du domaine biomédical, en particulier la détection des mentions de bactéries et de biotopes [?].

---

2. Voir <http://bertrandmasson.free.fr/index.php?categorie6/latex-pgf-tikz> pour de nombreux exemples utiles.

### A.6.2 Format

L<sup>A</sup>T<sub>E</sub>X gère automatiquement le format de présentation des références, selon que l'article cité a été rédigé par un auteur [?] (auquel cas sont mentionnés le nom et l'année), deux auteurs [?] (les noms des deux auteurs et l'année), ou plus de deux auteurs [?] (le nom du premier auteur, la mention *et al.*<sup>3</sup>, et l'année).

---

3. Locution latine signifiant « et d'autres ».

## PRINCIPES À SUIVRE

### B.1 Le sujet de votre mémoire

Vous avez acquis, au cours de l'année 2015-2016, des compétences d'ingénieur-linguiste; vous savez donc analyser un problème, proposer une méthodologie permettant d'arriver à une solution et montrer les limites de cette dernière. C'est cette démarche qui constituera le fil directeur de votre mémoire.

Ce travail devra être original et personnel. Le cadre de votre travail est naturellement la linguistique et, étant donné le diplôme que vous préparez, la linguistique appliquée, plutôt que théorique. Ceci ne veut néanmoins pas dire que vous ne devez pas situer votre démarche à l'intérieur d'un cadre théorique, au contraire. On souhaite cependant que ce cadre serve d'appui à la création ou à la transformation d'outils, à la mise au point de méthodologies vous permettant de proposer un résultat. Cela revient à dire que votre mémoire constitue une tentative de problématiser une approche méthodologique, de proposer une piste nouvelle, de comparer des méthodes, des outils, etc. Il contiendra en tout cas un état de l'art et s'appuiera sur une bibliographie précise et récente. L'état de l'art ne doit pas être déconnecté de la question traitée : on ne vous demande pas de « faire un état de l'art pour faire un état de l'art » mais, au contraire, de montrer comment se situe votre travail par rapport à cet état de l'art. Si votre sujet s'y prête, et afin d'en faciliter la réalisation, vous pouvez segmenter votre état de l'art en plusieurs parties ciblées à placer en tête des chapitres correspondant plutôt que d'écrire un chapitre consacré qui risque d'être généraliste et donc insuffisamment précis.

Vous devrez avoir choisi un sujet de mémoire à la mi-mai ou, à tout le moins, avoir réfléchi à des pistes sérieuses. Vous devrez vous assurer auprès d'un intervenant du TIM/ER-TIM que vous ne faites pas fausse route et que votre mémoire ne sera pas hors-sujet. Il s'agit d'éviter que vous ne traitiez un sujet dont les exigences techniques pourraient s'avérer supérieures à ce que vous croyez connaître. Le(s) stage(s) de fin d'études que vous devez entreprendre peu(t)/vent vous aider à affiner votre choix de sujet, mais vous devez garder à l'esprit que votre mémoire ne doit pas se confondre avec une description de votre stage. Notez bien que les rapports de stage ne sont pas pris en compte dans l'évaluation de votre Master.

Pour vous aider, vous pouvez consulter les meilleurs mémoires des années précédentes (et dont les résumés sont en ligne sur le site [www.er-tim.fr](http://www.er-tim.fr)). Évidemment, vous consulterez également les articles scientifiques liés à votre problématique : outre les connaissances que vous pourrez ainsi acquérir, cela vous permettra aussi de vous familiariser avec ce genre bien spécifique. Si vous ne trouviez pas de sujet vous permettant de mettre en pratique les connaissances acquises au cours de cette année, en

fonction de vos goûts et attentes personnels ou professionnels, nous vous en proposons un (consultez-nous, donc).

## B.2 L'encadrement du mémoire

Vous avez toute latitude pour choisir, selon affinités, la/les personne(s) qui va/vont diriger vos recherches. Mais un/des intervenant(s) du TIM/ER-TIM figurera/ont nécessairement dans votre jury lors de la soutenance. Il faut donc nécessairement avoir pris contact avec ces personnes et s'assurer de leur collaboration. Si vous envisagez de faire une thèse ensuite, il est recommandé de solliciter un enseignant assimilé professeur ou habilité à diriger des recherches ou de mettre en place un co-encadrement en ce sens.

En règle générale, le TIM/ER-TIM souhaite, autant que faire se peut, que les personnes qui vous ont encadré lors de votre stage et qui ont pu vous conseiller pour la rédaction de votre mémoire, soient présentes lors de la soutenance. Elles apportent un complément d'information interne sur le stage et les conditions de réalisation du mémoire, éclairage qui peut être tout à fait pertinent.

Si vous rencontrez des problèmes et souhaitez poser des questions, il est impératif, dans un premier temps, de les formuler par courrier électronique plutôt que de venir immédiatement au TIM/ER-TIM, riche en compétences mais pauvre en personnel. Par ailleurs, vous ne devez pas envoyer par courrier électronique des centaines de pages à fin de re-lecture : lorsqu'une pré-version de votre travail vous semblera digne de relecture, déposez-la au TIM/ER-TIM, ou postez-la.

## B.3 L'évaluation du mémoire

L'évaluation du mémoire est fonction de la qualité de votre travail écrit et de votre capacité à répondre aux questions, remarques, critiques qui peuvent vous être adressées pendant la soutenance. La qualité du travail écrit dépend de plusieurs critères, dont voici une liste non-exhaustive :

- votre mémoire forme-t-il un ensemble cohérent qui doit son unité à la volonté de répondre à une problématique bien définie ?
- votre mémoire est-il réutilisable par une personne souhaitant faire un bilan de la problématique soulevée, tant du point de vue fond que forme (clarté de la bibliographie, description en annexe des outils utilisés avec liens aux sources, disponibilités des sources sur le CD-ROM d'accompagnement de votre mémoire, index permettant une consultation rapide, table des matières, pagination, etc.) ?
- votre mémoire répond-t-il vraiment à l'objectif fixé au départ ? le titre de votre mémoire correspond-il vraiment au contenu ? les mots-clés qui seront mis en ligne sont-ils pertinents ?
- votre mémoire met-il en valeur un angle de vue original sur un savoir-faire classique ?
- votre mémoire parvient-il à mettre la théorie à l'épreuve ? Êtes-vous capable de fournir des résultats, des exemples, un bilan d'expérience, des critères d'évaluation, une évaluation ?
- la bibliographie doit être totalement normalisée, de façon à permettre une consultation aisée, les annexes contiendront un descriptif pratique et les références des outils utilisés, un échantillon des corpus utilisés et des programmes

que vous avez écrits et, de manière générale, tout ce qui peut illustrer le travail réalisé. Attention, pour des raisons de place, vous ne devez évidemment pas présenter tous vos corpus et tous vos programmes en annexe, mais un simple échantillon. En revanche, corpus<sup>1</sup> et programmes figureront impérativement et exhaustivement sur le CD fourni.

La qualité de votre prestation orale est importante. Vous devrez vous assurer, en particulier, que :

- vous savez vous affranchir du plan de votre mémoire mais vous devez néanmoins faire un bref résumé de la problématique car tous les membres du jury n'auront pas lu votre mémoire
- vous donnez des exemples concrets des questions qui se sont posées et des solutions apportées, de façon à montrer que vous ne traitez pas le sujet de façon purement théorique
- vous savez situer la problématique de votre mémoire par rapport aux travaux les plus connus et les plus récents sur la question
- vous savez faire le lien entre les connaissances acquises au cours de l'année et la mise en pratique de ces connaissances lors de la réalisation du mémoire
- vous savez répondre aux questions ou critiques qui vous sont soumises

## B.4 La démarche à suivre pour soutenir

Trois semaines avant la date de soutenance, vous devez envoyer une version présentable de votre mémoire à votre encadrant et à l'équipe de formation, pour déterminer si le mémoire est soutenable. Vous devez remettre une version papier définitive de vos mémoires au moins 15 jours avant la soutenance.

- La soutenance pour la première session est fixée entre le 20 et le 24 juin 2016 (à préciser) pour ceux d'entre vous qui candidateraient à un contrat doctoral INaLCO (voir la procédure sur le site [www.inalco.fr](http://www.inalco.fr), le comité de sélection ayant lieu le 1 juillet 2016).
- Pour la deuxième session (inscription en doctorat à l'INaLCO selon la procédure normale), la soutenance est fixée le 30 septembre 2016.
- Pour la dernière session, la date de soutenance est fixée le 18 novembre 2016.

Vous devez déposer votre travail au moins deux semaines avant d'espérer soutenir. Il faut en effet qu'il soit lu, puis, si nécessaire, amendé et corrigé – voire rejeté et réécrit – de façon que la soutenance ne verse pas dans la critique systématique.

Au plus tard la veille de votre soutenance, vous aurez envoyé à [crim@inalco.fr](mailto:crim@inalco.fr) et à [sophie.urbaniaik@inalco.fr](mailto:sophie.urbaniaik@inalco.fr) un résumé de votre mémoire de 10 lignes maximum ainsi que 5 mots-clés permettant de situer votre travail. Attention, ces informations sont destinées à être consultées et doivent donc être le reflet fidèle de votre travail final.

Une fois votre travail accepté, nous vous proposerons un ordre de passage pour la soutenance. Vous devrez fournir 3 exemplaires/support-papier et 3 exemplaires/support-électronique de votre mémoire (ces exemplaires sont destinés aux membres du jury et aux futurs étudiants). Sur le 4ème de couverture vous agraferez une enveloppe format 21-27 qui contiendra le CD correspondant à votre travail. Ce CD contiendra, outre la version électronique de votre mémoire, toutes les annexes ne pouvant figurer

---

1. Vérifiez toutefois que vous avez le droit de reproduire tout ou partie du corpus sur lequel vous aurez travaillé, en particulier pour les corpus de documents cliniques.

rer dans le mémoire pour des raisons de place : corpus, code source des outils utilisés, polices de caractères utilisées, code des programmes que vous avez élaborés.

## INDEX

Bibliographie, 41

F-mesure, 41

Mise en forme, 40

Précision, 41

Rappel, 41

Schéma, 39

Tableau, 40